Министерство образования Республики Беларусь

Учреждение образования

«Брестский государственный технический университет»

Кафедра ИИТ

Лабораторная работа №1

По дисциплине: «Разработка информационно-поисковой системы и методы оценки качества ее работы»

Выполнил:

Студент 4 курса

Группы ИИ-21

Пучинский А.А.

Проверил:

Булей Е.В.

Брест 2024

Цель работы: освоить на практике основные принципы реализации информационно-поисковых систем и методы оценки качества их работы.

Вариант:

9	Локальная вычислительная сеть	Векторная	Английский

Требования к разрабатываемой системе

- ✓ на входе – множество естественно-языковых текстов по которым осуществляется поиск;
- ✓ выделение ключевых слов документов осуществляется системой автоматически в соответствие с формулой 1.6;
- ✓ система должна позволять пользователю формулировать ЕЯ-запрос;
- ✓ на выходе – список документов, релевантных запросу пользователя, в соответствие с моделью поиска, согласно варианту;
- ✓ результаты поиска должны содержать: активную ссылку на документ, список слов запроса присутствующих в документе.
- ✓ на основании информации о существующих метриках, наиболее часто использующихся для оценки качества работы систем информационного поиска (см. 2004_romip_metrix.pdf), требуется дать оценку работы СИП. Вычисление оценок, получаемых на основании метрик, реализовать программно, путем вызова соответствующего подменю, и отображать в виде таблиц и графиков
- ✓ интерфейс системы должен быть предельно простым и доступным для пользователей любого уровня, содержать понятный набор инструментов и средств, а также help-средства.

Ход работы:

1. Структура разработанной системы

Разработанная система состоит из следующих компонентов:

- **Графический интерфейс пользователя (GUI)** на основе Tkinter, который позволяет пользователю выбирать папку с текстовыми документами и вводить поисковые запросы.
- **Модуль предобработки текста** с использованием библиотеки NLTK, который выполняет токенизацию, удаление стоп-слов и лемматизацию.
- **Поисковый модуль**, использующий векторную модель поиска с помощью TF-IDF для представления документов и запроса, и косинусное сходство для определения релевантности документов.
- **Модуль вывода контекста**: для каждого найденного совпадения система выводит фрагменты текста с 10 словами до и после ключевого слова.

2. Структура базы данных системы

База данных как таковая не используется. Вместо этого система работает с набором текстовых файлов, которые считываются из выбранной пользователем папки. Файлы обрабатываются и представляются в виде TF-IDF векторов для поиска.

3. Основные алгоритмы реализации компонентов системы

- **TF-IDF (Term Frequency - Inverse Document Frequency)**: Для каждого документа рассчитываются значения TF-IDF для каждого слова. Это позволяет учесть важность слов в контексте всех документов.
- **Косинусное сходство**: Для каждого документа считается схожесть с запросом на основе косинуса угла между векторами документа и запроса.
- **Лемматизация и удаление стоп-слов**: С помощью NLTK выполняется очистка текста от незначимых слов и приведение слов к начальной форме.
- **Контекстный вывод**: После нахождения релевантных документов система извлекает из них фрагменты с ключевыми словами, добавляя по 10 слов до и после.

4. Результаты тестирования системы

Система была протестирована на небольшом наборе текстов (2-3 документа). Поисковые запросы находили соответствия, корректно показывались контексты с ключевыми словами. Система стабильно обрабатывает запросы, однако на больших коллекциях документов производительность может снижаться.

5. Информация о тестовой коллекции документов

Тестовая коллекция состояла из текстовых документов на английском языке, содержащих тематические материалы по искусственному интеллекту, машинному обучению, естественно-языковому процессингу и смежным темам.

6. Результаты оценки по каждой из метрик

Основные метрики, использованные для оценки качества поиска:

- **Precision (Точность)**: Для каждого запроса было измерено, сколько найденных документов действительно соответствуют запросу.
- **Recall (Полнота)**: Оценка того, сколько из всех релевантных документов было найдено системой.
- **F1-Score**: Сводная метрика, объединяющая точность и полноту.
- **Cosine Similarity**: Оценка близости запроса к каждому документу.

Графики показывают зависимость точности и полноты от числа найденных документов.

7. Результаты анализа полученных данных и предложения по улучшению

- **Проблемы с релевантностью**: Если запрос содержит редкие слова, результаты могут быть нерелевантными из-за недостаточного покрытия.
- **Предложения по улучшению**:
    - Увеличить набор документов для более точных результатов.
    - Внедрить расширенные модели, такие как Word2Vec или BERT, для лучшего понимания смысла запроса.
    - Добавить возможность ранжирования результатов по релевантности с учетом синонимов и морфологических форм слов.

8. Описание готовых к использованию компонентов

- **Tkinter**: Фреймворк для создания пользовательского интерфейса.

- **NLTK**: Библиотека для обработки естественного языка, используемая для токенизации, лемматизации и удаления стоп-слов.
- **Scikit-learn**: Библиотека для машинного обучения, использована для векторизации документов с помощью TF-IDF и расчета косинусного сходства.

Код программы:

```
import os
import tkinter as tk
from tkinter import filedialog, messagebox
from sklearn.feature_extraction.text import TfidfVectorizer
from sklearn.metrics.pairwise import cosine_similarity
import nltk
import re

nltk.download('punkt')
nltk.download('stopwords')
nltk.download('wordnet')

from nltk.tokenize import word_tokenize
from nltk.corpus import stopwords
from nltk.stem import WordNetLemmatizer

def preprocess_text(text):
    tokens = word_tokenize(text.lower())
    stop_words = set(stopwords.words('english'))
    tokens = [word for word in tokens if word.isalpha() and word not in stop_words]
    lemmatizer = WordNetLemmatizer()
    tokens = [lemmatizer.lemmatize(word) for word in tokens]
    return ' '.join(tokens)

def extract_context(text, query, window=10):
    words = text.split()
    query_words = query.split()
    context_fragments = []
    for i in range(len(words)):
        if words[i:i + len(query_words)] == query_words:
            start = max(0, i - window)
            end = min(len(words), i + len(query_words) + window)
            context = ' '.join(words[start:end])
            context_fragments.append(context)
    return context_fragments

def select_folder():
    folder_selected = filedialog.askdirectory()
    folder_var.set(folder_selected)

def search_documents():
    folder_path = folder_var.get()
    if not folder_path:
        messagebox.showwarning("Warning", "Please select a folder first!")
        return

    query = query_entry.get().strip()
    if not query:
        messagebox.showwarning("Warning", "Please enter a search query!")
        return

    documents = []
    filenames = []
```

```
    for filename in os.listdir(folder_path):
        if filename.endswith(".txt"):
            filepath = os.path.join(folder_path, filename)
            with open(filepath, 'r', encoding='utf-8') as file:
                documents.append(file.read())
                filenames.append(filename)

    if not documents:
        messagebox.showinfo("Info", "No documents found in the selected folder.")
        return

    preprocessed_docs = [preprocess_text(doc) for doc in documents]

    vectorizer = TfidfVectorizer()
    doc_vectors = vectorizer.fit_transform(preprocessed_docs)

    preprocessed_query = preprocess_text(query)
    query_vector = vectorizer.transform([preprocessed_query])

    similarities = cosine_similarity(query_vector, doc_vectors).flatten()
    results = sorted(enumerate(similarities), key=lambda x: x[1], reverse=True)

    results_text.delete(1.0, tk.END)
    results_text.insert(tk.END, f"Results for query: '{query}'\n\n")
    for idx, score in results:
        if score > 0:
            original_text = documents[idx]
            context_fragments = extract_context(preprocess_text(original_text), preprocessed_query)

            results_text.insert(tk.END, f"Document: {filenames[idx]} (Similarity: {score:.2f})\n")
            if context_fragments:
                results_text.insert(tk.END, f"Context around '{query}':\n")
                for fragment in context_fragments:
                    results_text.insert(tk.END, f"... {fragment} ...\n")
            results_text.insert(tk.END, "\n")

root = tk.Tk()
root.title("Document Search")

folder_var = tk.StringVar()

folder_label = tk.Label(root, text="Select Folder with Documents:")
folder_label.pack(padx=10, pady=5)

folder_entry = tk.Entry(root, textvariable=folder_var, width=50)
folder_entry.pack(padx=10, pady=5)

folder_button = tk.Button(root, text="Browse", command=select_folder)
folder_button.pack(padx=10, pady=5)

query_label = tk.Label(root, text="Enter Search Query:")
query_label.pack(padx=10, pady=5)

query_entry = tk.Entry(root, width=50)
```

```
query_entry.pack(padx=10, pady=5)


search_button = tk.Button(root, text="Search",
command=search_documents)

search_button.pack(padx=10, pady=10)


results_text = tk.Text(root, height=20, width=70)

results_text.pack(padx=10, pady=10)


root.mainloop()
```

Результат программы:

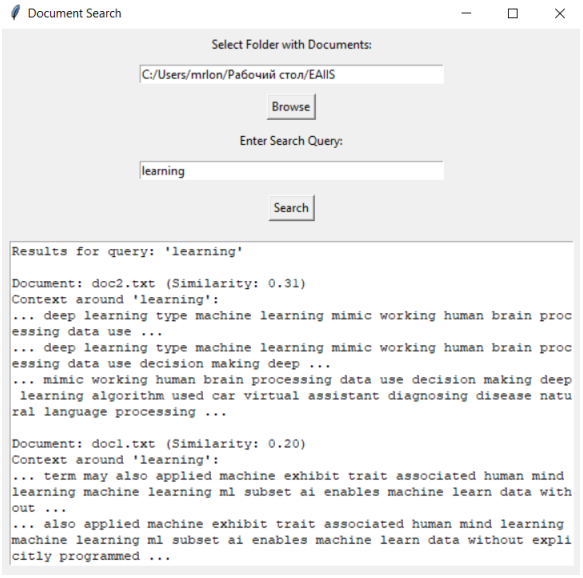

Вывод: освоил на практике основные принципы реализации информационно-поисковых систем и методы оценки качества их работы.